

GRAPH COLORING

SOTA SI BENCHMARK-URI

1. INTRODUCERE

Acest document sintetizeaza stadiul actual al cercetarii pentru problema de graph coloring si prezinta benchmark-urile standard care pot fi folosite pentru evaluarea proiectului ales.

Problema de graph coloring consta in atribuirea unei culori fiecarui nod al unui graf astfel incat doua noduri adiacente sa nu aiba aceeasi culoare, folosind un numar cat mai mic de culori. Este o problema clasica de optimizare combinatoriala, cu aplicatii in alocarea registrelor, planificarea orarelor, alocarea frecventelor si partitionarea resurselor.

Literatura recenta poate fi organizata in patru directii principale: metode exacte, euristici clasice si local search, metode hibride si abordari bazate pe deep learning. Pentru un proiect modern, cele mai relevante comparatii sunt cu DSATUR, greedy, Tabu Search sau TabuCol si, daca este posibil, cu o metoda memetica.

2. STADIUL ACTUAL AL CERCETARII

2.1. Metode exacte

Metodele exacte sunt importante atunci cand se urmareste obtinerea unei solutii optime si demonstrarea optimalitatii numarului cromatic. Acestea sunt mai potrivite pentru instante mici si medii, deoarece costul computational creste rapid pe grafuri mari.

Un punct de plecare bun este lucrarea *Exact Algorithms for the Graph Coloring Problem*, publicata de Lima, Carmo si Campos in 2018.

Link: https://seer.ufrgs.br/index.php/rita/article/view/RITA_Vol25_Nr4_57

Lucrarea sintetizeaza principalele familii de algoritmi exacti, precum Dynamic Programming, Branch-and-Bound si Integer Linear Programming. Sunt discutate si variante exacte ale algoritmului DSATUR, precum si metode inspirate din arborii lui Zykov. Articolul este util deoarece ofera o imagine clara asupra modului in care problema poate fi abordata riguros.

O alta referinta importanta este *A Branch-and-Cut Algorithm for Graph Coloring*, semnata de Mendez-Diaz si Zabala in 2006.

Link: <https://www.sciencedirect.com/science/article/pii/S0166218X05003094>

Autorii formuleaza problema ca model de programare liniara intreaga si propun o abordare de tip branch-and-cut. Un aspect important al lucrarii este analiza simetriilor dintre culori, care afecteaza performanta modelelor ILP. Articolul este relevant deoarece arata cum poate fi imbunatatita rezolvarea exacta printr-o formulare matematica bine construita.

O directie exacta mai moderna este prezentata in *Graph Coloring with Decision Diagrams*, publicata de van Hoeve in 2021.

Link: <https://optimization-online.org/wp-content/uploads/2021/01/8215.pdf>

Lucrarea propune un cadru iterativ bazat pe decision diagrams relaxate, folosite pentru obtinerea de lower bounds si pentru ghidarea cautarii catre solutii fezabile. Este relevanta pentru proiect deoarece reprezinta un exemplu modern de metoda exacta competitiva.

2.2. Euristici clasice si local search

Chiar daca proiectul urmareste directia deep learning, baseline-urile clasice raman obligatorii. In graph coloring, DSATUR este una dintre cele mai importante euristici constructive, iar metodele de local search si tabu search continua sa fie foarte puternice in practica.

Aceste metode nu garanteaza optimalitatea, dar obtin adesea rezultate foarte bune pe grafuri dificile. Din acest motiv, un proiect serios ar trebui sa includa cel putin DSATUR, greedy si o metoda de local search ca puncte de comparatie.

2.3. Deep learning pentru graph coloring

Una dintre cele mai cunoscute lucrari din aceasta directie este *Graph Colouring Meets Deep Learning: Effective Graph Neural Network Models for Combinatorial Problems*, publicata de Lemos si colaboratorii in 2019.

Link: <https://arxiv.org/abs/1903.04598>

Lucrarea studiaza daca problema de graph coloring poate fi abordata eficient cu Graph Neural Networks. Autorii propun un model GNN care decide daca un graf poate fi colorat cu un numar fix de culori. Modelul invata prin schimb de mesaje intre noduri si reprezentari ale culorilor, iar embedding-urile invatate pot sugera si solutii constructive. Articolul este important deoarece arata direct cum poate fi aplicat deep learning-ul pe aceasta problema.

O alta directie este prezentata in *Graph Coloring with Physics-Inspired Graph Neural Networks*, publicata de Schuetz si colaboratorii in 2022.

Link: <https://arxiv.org/abs/2202.01606>

Aici problema este reformulata ca sarcina de clasificare multclas pe noduri, iar procesul de invatare este inspirat de modelul Potts din fizica statistica. Autorii construiesc un model care atribuie culori nodurilor si sustin ca metoda poate scala la grafuri foarte mari. Lucrarea este relevanta deoarece propune o perspectiva diferita fata de GNN-urile standard.

Pe partea critica, una dintre cele mai utile lucrari este *Rethinking Graph Neural Networks for the Graph Coloring Problem*, publicata de Li si colaboratorii in 2022.

Link: <https://arxiv.org/abs/2208.06975>

Autorii explica de ce multe GNN-uri standard nu performeaza bine pe graph coloring. Problema este privita ca una de tip heterophily, in timp ce multe GNN-uri sunt proiectate mai ales pentru grafuri de tip homophily. Lucrarea este valoroasa deoarece justifica de ce nu orice arhitectura neurala este potrivita pentru acest task.

2.4. Metode hibride

Una dintre cele mai solide directii din literatura recenta este cea a abordarilor hibride. Un exemplu important este *A Deep Learning Guided Memetic Framework for Graph Coloring Problems*, publicata de Goudet, Grelrier si Hao in 2022.

Link: <https://www.sciencedirect.com/science/article/abs/pii/S0950705122010796>

Autorii nu inlocuiesc euristicele clasice, ci folosesc deep learning-ul pentru a ghida mai eficient cautarea euristica intr-un cadru memetic. Rezultatele raportate sunt foarte competitive, ceea ce sugereaza ca cele mai bune performante apar adesea in metode care combina invatarea automata cu euristicele consacrate.

3. CONCLUZIE ASUPRA LITERATURII

Din analiza lucrarilor de mai sus rezulta cateva idei clare. Metodele exacte raman importante ca punct de referinta. Euristicele clasice sunt baseline-uri obligatorii. Metodele bazate exclusiv pe GNN sunt promitatoare, dar au limitari reale pe graph coloring. In prezent, cele mai credibile rezultate practice par sa vina din abordari hibride, in care invatarea automata completeaza si ghideaza cautarea euristica.

4. BENCHMARK-URI SI DATASET-URI RECOMANDATE

Pentru evaluarea unui proiect de graph coloring, cel mai potrivit punct de plecare il reprezinta benchmark-urile standard din familia DIMACS si COLOR. Aceste instante sunt folosite frecvent in literatura si permit comparatii corecte cu lucrarile existente.

Resurse utile:

Graph Coloring Instances: <https://mat.tepper.cmu.edu/COLOR/instances.html>

COLOR02: <https://mat.tepper.cmu.edu/COLOR02/>

DIMACS Graphs and Best Algorithms: <https://cedric.cnam.fr/~porumbed/graphs/>

Graph Coloring Benchmarks - Links: <https://sites.google.com/site/graphcoloring/links>

4.1. Familii importante de instante

DSJC

Familia DSJC contine grafuri random si este foarte frecvent folosita in literatura. Exemple reprezentative sunt DSJC125.1, DSJC125.5, DSJC250.5, DSJC500.5 si DSJC1000.5. Aceste instante sunt potrivite pentru comparatii standard si pentru evaluarea generalizarii.

DSJR

Familia DSJR include grafuri geometrice si versiuni complementare, precum DSJR500.1, DSJR500.1c, DSJR500.5 si DSJR500.5c. Acestea sunt utile pentru a testa sensibilitatea metodei la structura grafului.

Flat

Instantele flat, precum flat300_20_0, flat300_28_0, flat1000_50_0 sau flat1000_76_0, apar frecvent in lucrarile de graph coloring deoarece sunt cunoscute ca fiind dificile pentru multe metode simple.

Leighton

Grafurile Leighton, de tipul le450_5a, le450_15b sau le450_25c, sunt benchmark-uri clasice si utile pentru comparatia cu literatura traditionala.

Queen

Grafurile queen, cum sunt queen5_5, queen8_8 sau queen13_13, sunt potrivite pentru validare rapida si interpretare structurala.

Myciel

Grafurile myciel, de exemplu myciel3 pana la myciel7, au relevanta teoretica si sunt utile pentru experimente pe instante mici si explicabile.

Alte instante

Instante precum anna, david, homer, games120, school1 sau familia miles completeaza bine un benchmark variat.

4.2. Selectie pentru proiect

Pentru un proiect bine echilibrat, benchmark-ul poate fi impartit in trei niveluri.

Instante mici:

myciel3 - myciel7, queen5_5, queen6_6, anna, david, games120

Instante medii:

le450, school1, flat300, DSJC125, DSJC250

Instante mari:

DSJC500, DSJC1000, DSJR500, flat1000

Aceasta selectie permite evaluarea comportamentului pe grafuri mici si explicabile, comparatia cu benchmark-uri clasice din literatura si observarea robustetii metodei pe instante grele.

5. BIBLIOGRAFIE

de Lima, A. M., Carmo, R., Campos, V. *Exact Algorithms for the Graph Coloring Problem*, 2018.

https://seer.ufrgs.br/index.php/rita/article/view/RITA_Vol25_Nr4_57

Mendez-Diaz, I., Zabala, P. *A Branch-and-Cut Algorithm for Graph Coloring*, 2006.

<https://www.sciencedirect.com/science/article/pii/S0166218X05003094>

van Hoeve, W.-J. *Graph Coloring with Decision Diagrams*, 2021.

<https://optimization-online.org/wp-content/uploads/2021/01/8215.pdf>

Lemos, H., Prates, M., Avelar, P., Lamb, L. C. *Graph Colouring Meets Deep Learning*, 2019.

<https://arxiv.org/abs/1903.04598>

Schuetz, M. J. A., Brubaker, J. K., Zhu, Z., Katzgraber, H. G. *Graph Coloring with Physics-Inspired Graph Neural Networks*, 2022.
<https://arxiv.org/abs/2202.01606>

Li, W., Li, R., Ma, Y., Chan, S. O., Pan, D., Yu, B. *Rethinking Graph Neural Networks for the Graph Coloring Problem*, 2022.
<https://arxiv.org/abs/2208.06975>

Goudet, O., Grelier, C., Hao, J.-K. *A Deep Learning Guided Memetic Framework for Graph Coloring Problems*, 2022.
<https://www.sciencedirect.com/science/article/abs/pii/S0950705122010796>